

機械学習を 解釈する技術2

廣田雄亮

2章

「解釈性」の理解


解釈性を理解する上で

前提

線形回帰モデルを解釈する方法を学ぶ.

回帰問題とは
目的変数が連続地の場合に予測を行うタスク

線形回帰モデルはシンプル
ふるまいに対する透明性が高い
→ 解釈性が高い



線形回帰モデルが備える解釈性

特徴量と予測値の関係が明らかであること

1. 特徴量とモデルの予測値の平均的な関係

→ PD

2. 特徴量の重要度

→ PFI

3. 特徴量と予測値のインスタンス毎の関係

→ ICE


4. モデルの出したインスタンス毎の
予測値の理由

→ SHAP

線形回帰モデルの評価指標



- **RMSE** 小さいほど良い
平均的な予測誤差

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$



- **R² (決定係数)** 大きいほど良い
単純に平均値を返すモデルと比較して,
どの程度精度が良いか

$$R^2 \equiv 1 - \frac{\sum_{i=1}^N (y_i - f_i)^2}{\sum_{j=1}^N (y_j - \bar{y})^2}$$



特徴量とモデルの予測値の平均的な関係

$$f(x_1, x_2, x_3) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$$

特徴量 x_1 が1単位増加すると予測値は β_1 増加する

このことは全てのインスタンスで共通



回帰係数は特徴量とモデルの
予測値の**平均的な (インスタンス毎ではない)**
関係を解釈している

特徴量と予測値のインスタンス毎の関係(1/3)

$$f(x) = \beta_0 + \beta_1 x + \beta_2 x^2$$

特徴量 x が1単位増加すると予測値の変化量は
上記の式を微分すると分かる

$$\frac{\partial f(x)}{\partial x} = \beta_1 + 2\beta_2 x$$

特徴量と予測値のインスタンス毎の関係(2/3)

$(\beta_1, \beta_2) = (1, 2)$ のとき

$x = 1$ のインスタンスでは, x が1増加した場合
予測値の変化量は $1 + 2 \times 2 \times 1 = 5$

$x = 10$ のインスタンスでは, x が1増加した場合
予測値の変化量は $1 + 2 \times 2 \times 10 = 41$

特徴量と予測値の**各データ毎**の関係が明らか

交互作用がある場合

$$f(x_1, x_2) = \beta_0 + \beta_1 x_1 + \underline{\beta_2 x_1 x_2}$$

特徴量 x が1単位増加すると予測値の変化量は

$$\frac{\partial f(x_1, x_2)}{\partial x} = \beta_1 + \beta_2 x_2$$

交互作用がある場合

$$f(x_1, x_2) = \beta_0 + \beta_1 x_1 + \underline{\beta_2 x_1 x_2}$$

$(\beta_1, \beta_2) = (1, 2)$ のとき

$x_2 = 1$ のインスタンスでは, x_1 が1増加した場合
予測値の変化量は $1 + 2 \times 1 = 3$

$(\beta_1, \beta_2) = (1, 2)$ のとき

$x_2 = 10$ のインスタンスでは, x_1 が1増加した場合
予測値の変化量は $1 + 2 \times 10 = 21$

交互作用がある場合

$$f(x_1, x_2) = \beta_0 + \beta_1 x_1 + \underline{\beta_2 x_1 x_2}$$

$(\beta_1, \beta_2) = (1, 2)$ のとき

$x_2 = 1$ のインスタンスでは、 x_1 が1増加した場合

予測値の変化量は $1 + 2 \times 1 = \underline{3}$

$(\beta_1, \beta_2) = (1, 2)$ のとき

$x_2 = 10$ のインスタンスでは、 x_1 が1増加した場合

予測値の変化量は $1 + 2 \times 10 = \underline{21}$

インスタンス毎の
説明が可能

回帰係数による重要度比較

$$f(x_1, x_2, x_3) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$$

特徴量 (x_1, x_2, x_3) が1単位ずつ増加した場合の
予測値の変化量はそれぞれ ($\beta_1, \beta_2, \beta_3$)

($\beta_1, \beta_2, \beta_3$) = (0, 1, 10) の場合

- 最も予測値が変動するのは x_3
- x_1 は全く影響はない

ように見える.

回帰係数による重要度比較

回帰係数とは

特徴量が1単位増加した場合の予測値に与える影響

特徴量毎に「1単位増加する」ことの意味が
大きく異なるケースがある



特徴量のスケールを揃えてから比較するべき

特徴量のスケールが異なる場合

例

現職年収予測値(万円) =

$$1 \times \text{前職年数(万円)} + 100 \times \text{現職経験年数}$$

前職年収は, 300万 ~ 1000万 といった場合に
考えられる範囲が広い

経験年数は, 1年 ~ 60年 といった場合に
考えられる範囲が狭い

⇒ 正答な比較が難しい

標準化

特徴量のスケールが異なる場合

⇒ 標準化を行い、各特徴量のスケールを同じにして、回帰係数を比較

標準化

平均値からの偏差を標準偏差で割ること.

平均は0, 分散は1となる.

$$\tilde{x}_i = \frac{x_i - \bar{x}}{\widehat{SD}(x)}$$

$$\text{平均: } \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

$$\text{標準偏差: } \widehat{SD}(x) = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2}$$